



Введение в Линейную регрессию

Преподаватель: Герард Костин

План

Введение

- Постановка задачи машинного обучения
- Задача регрессии
- Линейная регрессия
- Метод наименьших квадратов
- Мультиномиальная регрессия
- Кривые обучения



Постановка Задачи

- Пусть

- X — множество описаний объектов,
- Y — множество допустимых ответов.

- Существует неизвестная целевая зависимость y^*

- отображение $y^* : X \rightarrow Y$
- значения y^* известны только на объектах конечной обучающей выборки X^n
- $X^n = \{(x_1, y_1), \dots, (x_n, y_n)\}$

- Требуется построить алгоритм a , который приближал бы неизвестную целевую зависимость как на элементах выборки X^n , так и на всём множестве X .

Функционал качества и функция потерь

- Вводится функция потерь $L(y, y')$, характеризующая величину отклонения ответа $y = a(x)$ от правильного ответа y' на произвольном объекте $x \in X$.
- Типичный выбор функции потерь:
 - В задачах классификации $L(y, y') = [y \neq y']$ (т.е. число ошибок классификации);
 - В задачах регрессии $L(y, y') = (y - y')^2$.
- Функционал качества
 - характеризует среднюю ошибку (эмпирический риск) алгоритма a на произвольной выборке X^n
 - $$Q(a, X^n) = \frac{1}{n} \sum_{i=1}^n L(a(x_i), y^*(x_i)).$$
- Метод минимизации эмпирического риска
 - Требуется найти алгоритм a^* , минимизирующий среднюю ошибку на обучающей выборке:
 - $$a^* = \arg \min_{a \in A} Q(a, X^n).$$

Признаки

Типы признаков

"бинарный" признак: ;

"номинальный" признак: — конечное множество;

"порядковый" признак: — конечное упорядоченное множество;




"количественный" признак: — множество действительных чисел.

Регрессия?

Интерполяция — способ выбрать из семейства функций ту, которая проходит через заданные точки.

Аппроксимация — способ выбрать из семейства «простых» функций приближение для «сложной» функции на отрезке, при этом ошибка не должна превышать определенного предела.

Регрессия — способ выбрать из семейства функций ту, которая минимизирует функцию потерь. Последняя характеризует насколько сильно пробная функция отклоняется от значений в заданных точках.



Регрессия


Уравнение, которое оценивает линию простой линейной регрессии:

$$Y=a+bx.$$


x называется независимой переменной или предиктором.

Y – зависимая переменная или переменная отклика.

- a – свободный член (пересечение) линии оценки; это значение Y , когда $x=0$.
- b – угловой коэффициент или градиент оценённой линии; она представляет собой величину, на которую Y увеличивается в среднем, если мы увеличиваем x на одну единицу.
- a и b называют коэффициентами регрессии оценённой линии, хотя этот термин часто используют только для b .




Метод наименьших квадратов



Метод наименьших квадратов

$$SSE(a, b) = SS_{residuals} = \sum_{i=1}^N \text{отклонение}_i^2 = \sum_{i=1}^N (y_i - f(x_i))^2 = \sum_{i=1}^N (y_i - a - b \cdot x_i)^2,$$



Метод наименьших квадратов

$$\text{SSE}(a, b) = \text{SS}_{\text{residuals}} = \sum_{i=1}^N \text{отклонение}_i^2 = \sum_{i=1}^N (y_i - f(x_i))^2 = \sum_{i=1}^N (y_i - a - b \cdot x_i)^2,$$

$$\frac{\partial}{\partial a} \text{SSE}(a, b) = -2 \sum_{i=1}^N (y_i - a - bx_i),$$

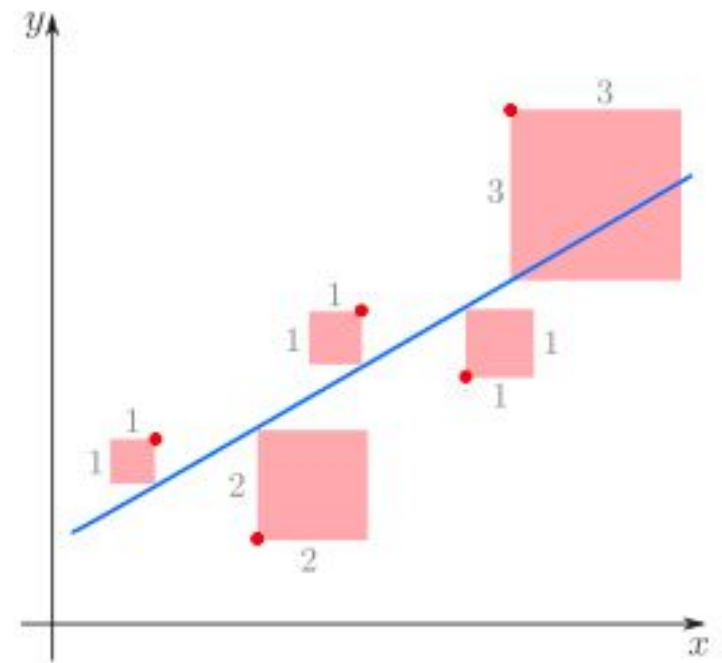
$$\frac{\partial}{\partial b} \text{SSE}(a, b) = -2 \sum_{i=1}^N (y_i - a - bx_i)x_i.$$

$$0 = -2 \sum_{i=1}^N (y_i - \hat{a} - \hat{b}x_i),$$

$$0 = -2 \sum_{i=1}^N (y_i - \hat{a} - \hat{b}x_i)x_i,$$

$$\hat{a} = \frac{\sum_i y_i}{N} - \hat{b} \frac{\sum_i x_i}{N},$$

$$\hat{b} = \frac{\frac{\sum_i x_i y_i}{N} - \frac{\sum_i x_i \sum_i y_i}{N^2}}{\frac{\sum_i x_i^2}{N} - \left(\frac{\sum_i x_i}{N}\right)^2}.$$



Мультиномиальная регрессия

- Дано

- $X = x^{(1)}, \dots, x^{(N)}$
- $x^{(k)}$ - вектор размерности D , поэтому размерность $X : (N \times D)$
- $Y = y^{(1)}, \dots, y^{(N)}; y^{(k)} \in R$

- Для некоторого примера $x^{(k)}$:

- $a(x^{(k)}) = \hat{y}^{(k)} = w_1 x_1^{(k)} + w_2 x_2^{(k)} + \dots + w_D x_D^{(k)} = w^T x^{(k)}$

- Целевая функция:

- $$L = \sum_i^N (y_i - \hat{y}_i)^2$$

- Найти: $w = ?$

Мультиномиальная регрессия

- $\frac{\partial L}{\partial w_j} = 0$

- $\frac{\partial L}{\partial w_j} = \sum_i 2(y_i - w^T x_i) \left(-\frac{\partial(w^T x_i)}{\partial w_j} \right)$

- $\frac{\partial w^T x_i}{\partial w_j} = x_{ij}$

- $\frac{\partial L}{\partial w_j} = \sum_i 2(y_i - w^T x_i)(-x_{ij}) = 0$

- $\frac{\partial L}{\partial w_j} = \sum_i 2(y_i - w^T x_i)(-x_{ij}) = 0$

- $\sum_i y_i x_{ij} = \sum_i (w^T x_i) x_{ij}$

- $x_{:,j}^T y = w^T (X^T x_{:,j})$ — при фиксированном j

- **для всех j сразу:** $X^T y = w^T (X^T X)$

- $(w^T (X^T X))^T = (X^T X) w$


- $X^T y = (X^T X) w$

- **решение:** $w = (X^T X)^{-1} X^T v$

$$X^+ = (X^T X)^{-1} X^T$$

Метод градиентного спуска

- $\mathbf{w}^{(next)} = \mathbf{w} - \eta \nabla_{\mathbf{w}} MSE(\mathbf{w})$
- $\nabla_{\mathbf{w}} MSE(\mathbf{w}) = \left(\frac{\partial(MSE(\mathbf{w}))}{\partial w_1}, \frac{\partial(MSE(\mathbf{w}))}{\partial w_2}, \dots, \frac{\partial(MSE(\mathbf{w}))}{\partial w_D} \right)^T$
- $\frac{\partial(MSE(\mathbf{w}))}{\partial w_j} = \frac{2}{n} \sum_{i=1}^n (\mathbf{w}^T \mathbf{x}^{(i)} - y^{(i)}) x_j^{(i)}$



Мультиномиальная регрессия

- Дано

- $X = x^{(1)}, \dots, x^{(N)}$
- $x^{(k)}$ - вектор размерности D , поэтому размерность $X : (N \times D)$
- $Y = y^{(1)}, \dots, y^{(N)}; y^{(k)} \in R$

- Для некоторого примера $x^{(k)}$:

- $a(x^{(k)}) = \hat{y}^{(k)} = w_1 x_1^{(k)} + w_2 x_2^{(k)} + \dots + w_D x_D^{(k)} = w^T x^{(k)}$

- Целевая функция:

- $$L = \sum_i^N (y_i - \hat{y}_i)^2$$

- Найти: $w = ?$

Кривые Обучения

